

Annotating translation errors in a machine translated novel

To be able to assess the quality of Google's Neural Machine Translation system on the translation of Agatha Christie's novel 'The Mysterious Affair at Styles' into Dutch all errors in the MT output will be indicated and labelled.

To be able to judge the quality of the translations, they will be marked for two important aspects: accuracy and fluency. Accuracy is concerned with the relationship between source text and target text, whereas fluency is concerned with the target text and language.

You will use a two-step approach. In a first step only the translation (target sentence) will be visible and all fluency errors will be annotated; in a second step, the source sentence will be displayed as well and you have to compare the source and target sentence and indicate all accuracy errors. To label the errors, you will make use of a predefined error taxonomy.

Step 1: Fluency errors

The goal of the first step is to annotate the machine translated text for fluency. Fluency can be described as respecting the norms of the target language and culture. A good translation should read as a native Dutch text. This includes respecting the conventions of the language (grammar, lexicon, spelling) as well as respecting the conventions of the text structure (paragraph content and coherence) and the text type, in this case literature.

As an annotator, it is your task to mark anything that does not follow the conventions of the Dutch language or that does not respect the demands of the text structure or the text type. To facilitate the task, different categories (Coherence, Lexicon, Style & register, Grammar & Syntax and Spelling) are predefined in WebAnno, along with their most important subcategories.

Note: Annotators can neglect punctuation marks.

Coherence

There is something wrong with the coherence of the text: lack of logical structure, confusing relationships, lack of logical structure, ...

Logical problem: the information as such is illogical/confusing/makes no sense when looking at the rest of the text

Logical problem | Coherence

We hadden een goed garen over oude tijden en het eindigde met zijn uitnodiging om naar Styles te gaan om daar mijn verlof door te brengen.

Logical problem | Coherence

"De mater zal blij zijn om je weer te zien ... na al die jaren," voegde hij eraan toe.

Logical problem | Coherence

"Ik heb een neef die borstvoeding geeft," merkte ik op.

Non-existing word: the word does not exist in Dutch and makes no sense

Mevr. Cavendish was echter een dame die graag haar eigen plannen maakte, en verwachtte

Logical problem | Coherence

dat andere mensen bij hen zouden vallen, en in dit geval had ze zeker de

Non-existing word | Coherence

zweephand

, namelijk: de

Non-existing word | Coherence

buidelrnen

.

Cultural reference: the word/phrase refers to something specific of the culture of the source, but makes no sense in the target language.

Cultural reference | Coherence

Een jong meisje in V.A. D. uniform liep licht over het gazon.

Discourse marker: the conjunction or linking word expresses a strange relationship

Discourse marker | Coherence

Inderdaad

, ik had hem

Discourse marker | Coherence

nog

nooit zo goed gekend.

Discourse marker | Coherence

Hij was ruim vijftien jaar ouder dan ik, in de eerste plaats

omdat

hij er amper vijfenveertig jaar uitzag.

Co-reference: co-reference problem, mismatch between entities, e.g. feminine pronoun to refer to a male person

Logical problem | Coherence

Ik was buiten het front geïnvalideerd; en na een aantal maanden in een nogal

Logical problem | Coherence

deprimerend herstellend huis te hebben doorgebracht, kreeg

Co-reference | Coherence

hij

een

maand ziekteverlof.

Logical problem | Coherence

Maar de

materie

was hem meteen

Logical problem | Coherence

aangegrepen

, nam hem aan als

Co-reference | Coherence

secretaresse

... je weet hoe ze altijd honderd

Logical problem | Coherence

samenlevingen

bestuurt? '

Inconsistency: a term or a notation is used inconsistently throughout the text

Het dorp Styles St. Mary lag ongeveer drie kilometer van het kleine station

Ze werkt in het Rode Kruis-ziekenhuis in Tadminster, zeven Inconsistency | Coherence mijl verderop.

Style & Register | Disfluent sentence/construction
" Waar is thee vandaag ... binnen of buiten?"

Inconsistency | Coherence
" Uit .

Verb tense: the tense of the verb is wrong/illogical in the context of the rest of the sentence/text

wilde, ongetemde geest in een prachtig geciviliseerd lichaam ... al deze dingen

Verb tense | Coherence
worden in mijn geheugen gebrand.

Lexicon

One lexical element does not entirely fit in the Dutch sentence.

Lexical choice: the meaning of the word is clear in the context, but it is not idiomatic in Dutch

Lexicon | Lexical choice Lawrence, de Lexicon | Lexical choice jongere , Lexicon | Lexical choice was Lexicon | Lexical choice een delicate jeugd geweest .
(flu)

Lexicon | Lexical choice
Ze wierp zich naast John op de grond en terwijl ik haar een bord boterhammen overhandigde, glimlachte ze naar me.

Lexicon | Lexical choice
een grondig fascinerende vrouw.

Wrong preposition: this expression requires a different preposition

Lexicon | Wrong preposition
Ik zag meteen door zijn gezicht dat er iets verontrustends had plaatsgevonden

Lexicon | Wrong preposition
De intense interesse die in het publiek werd gewekt door wat destijds bekend stond als 'The Styles Case' is nu enigszins verdwenen.

Grammar & syntax

Anything that does not follow the grammatical or structural rules of the Dutch language

Agreement: The sentence is grammatically incorrect because there is a mismatch between and article and noun, subject-verb, etc.

Grammar & Syntax | Agreement (flu)
Logical problem | Coherence Grammar & Syntax | Agreement
Dit vertrouwen zullen de sensationele geruchten stoppen die nog steeds bestaan.

Verb form: a grammatically incorrect verb form

Word order: a grammatically incorrect word order

Grammar & Syntax | Word order (flu) Grammar & Syntax | Word order
"Geen geheime hobby?" zij vroeg .

Extra words: The sentence is grammatically incorrect because there is a superfluous constituent or word. This can be a constituent that already appeared earlier in the sentence or a word that has been written twice in a row

Het dorp Styles St. Mary lag ongeveer drie kilometer van het kleine station en
Grammar & Syntax | Extra word
het Styles Court lag anderhalve kilometer aan de andere kant ervan.

Missing words: The sentence is grammatically incorrect because a necessary part of the structure is missing, this can be a preposition or an entire constituent such as an obligatory direct object.

Grammar & Syntax | Missing word
Daarna wendde zich tot zijn vrouw:

Grammar & Syntax | Missing word
Miss Howard schudde de hand met een stevige, bijna pijnlijke greep.

Grammar & Syntax | Missing word
Ik sprak mijn waardering uit, en John bracht me naar het huis en de brede trap op, die rechts en links voorwaarts slingerde naar verschillende vleugels van het gebouw.

Style & register

Disfluent sentence/construction: The sentence / constituent is not grammatically incorrect, but it is nonetheless very difficult to read, it could be translated in a much more idiomatic way.

Style & Register | Disfluent sentence/construction

Ik had een paar jaar heel weinig van hem gezien .

Style & Register | Disfluent sentence/construction

Mevr. Cavendish, die met zijn vader was getrouwd toen hij weduwnaar met twee zonen was,

Style & Register | Disfluent sentence/construction

was een knappe vrouw van middelbare leeftijd geweest, zoals ik haar herinnerde .

Repetition: The same or a very similar word/expression is used more than once

Style & Register | Repetition

en een knappe oude oude dame

Style & Register | Repetition

Cynthia Murdoch was een jong uitziend jong wezen, vol leven en kracht.

Register: The words have the same meaning, but the chosen word/expression is too formal/informal/... for the text or belongs to a regional variety of the language that is not entirely suitable for the target audience.'

Untranslated: A word / fragment of which a Dutch translation exists is left untranslated.

Style & Register | Untranslated

"En ze is doodsbang voor ' Sisters '."

Spelling

Spelling mistake: wrong spelling of a word

Spelling

"Pesten ze je dan?" Vroeg ik glimlachend.

Spelling

Een dame in een stevige tweedrok,

Other

Step 2: Accuracy errors

The goal of the second step is to annotate the machine translated text for accuracy.

Accuracy can be described as making sure the target text contains the same information as the source text. This means that all misinterpretations, contradictions, meaning shifts, additions or deletions are potential errors.

1. Before you start annotating for accuracy, make sure the Accuracy layer is selected in Webanno.
2. Accuracy annotations require two sets of annotations (one in source sentence and one in target sentence) and a "link" from source to target annotation.
3. First annotate the source text error, then annotate the corresponding translation in target text. Link annotation in the source text to the annotation in the target text with an arrow.

Accuracy has 6 main categories to choose from: Mistranslation, Do Not Translate, Untranslated, Addition, Omission and Capitalization & Punctuation.

Only Mistranslation has subcategories, namely Multiword, Word sense, Semantically unrelated, Part of Speech, Partially translated.

Mistranslation

Source content has been translated (when it should be translated) but the translation is incorrect. Choose the suitable subcategory.

Multiword: The translation is incorrect (and often too literal) because the English sentence contained a multi-word expression such as an idiom, a proverb, a collocation, a compound or a phrasal verb. Idiomatic expressions and proverbs are indicated with a paragraph sign (§) in Van Dale.



to fall in with = zich aansluiten bij
to have the whip hand = macht hebben over
purse strings = touwtjes van de geldbeurs

But you could have knocked us all down with a feather when, three months ago, she suddenly announced that she and Alfred were engaged!

Maar je had ons allemaal met een veer kunnen slaan toen ze drie maanden geleden plotseling aankondigde dat zij en Alfred verloofd waren!

knock down with a feather = zeer verbaasd zijn

Word sense: The target content refers to a different (and a wrong) sense of the source content.

A great sport ...old Evie!

Een geweldige sport ... oude Evie!

sport = meid (Brits-Engels; informeel)

Come and be refreshed ."

Kom en word vernieuwd ."

refresh = zich opfrissen

A man followed her, a suggestion of deference in his manner.

Een man volgde haar, een suggestie van eerbied op zijn manier.

suggestion = spoor, zweem

With the presence of Mr. Inglethorp, a sense of constraint and veiled hostility seemed to settle down upon the company .

Met de aanwezigheid van de heer Inglethorp leek een gevoel van dwang en verhulde vijandigheid zich te vestigen op het bedrijf .

constraint = *verkramp*t gedrag
company = *gezelschap*

Semantically unrelated: The meaning of one or more translated words is not related in any way to the meaning of the source word(s) and does not make any sense in the context.

Mrs. Inglethorp, however, seemed to notice nothing unusual. Her	Mistranslation Semantically Unrelated ✓ volubility
(acc) →	
Mevrouw Inglethorp leek echter niets ongewoons te merken. Haar	Mistranslation Semantically Unrelated Logical problem Coherence volmaaktheid

volubility = *welbespraaktheid*

Part-of-Speech: The translation represents an incorrect lexical category (Part-of-Speech) of the corresponding source text.

"	Mistranslation POS	(acc) →	Why	, if it isn't too delightful to see you again, Mr. Hastings, after all these years.
acc →	Mistranslation POS Discourse marker Coherence	Style & Register Disfluent sentence/construction	Waarom	, als het niet zo heerlijk is om je weer te zien, meneer Hastings, na al die jaren.

why = *tussenwerpsel hier: wel*

Partially translated: The translation is incorrect, e.g. due to the partial translation of a Dutch separable verb.

John	Mistranslation Partial practiced	for some time as a barrister,
(acc) →		
congenial life of a country squire .		
(acc) →		
(acc) →	Mistranslation Partial Logical problem Coherence	John oefende enige tijd als advocaat,

practice = *een beroep uitoefenen*

Other: None of the categories above

"Rotten little bounder too!" he said savagely.
"Rotte kleine bende ook!" zei hij woest.

bounder = onbeschoft persoon

"No, before the war I was in Lloyd's."
"Nee, voor de oorlog was ik in Lloyd's."

was = werkte ... bij

Do Not Translate

The source content is unnecessarily translated into target language when it should have been left untranslated.

Untranslated

The source text is not translated (but was copied to target) when it should have been translated into Dutch.

"The mater will be delighted to see you again...after all those years," he added.
"De mater zal blij zijn om je weer te zien ... na al die jaren," voegde hij eraan toe.

I recalled her as an energetic, autocratic personality, somewhat inclined to charitable and social
notoriety, with a fondness for opening bazaars and playing the Lady Bountiful.
Ik herinnerde me haar als een energieke, autocratische persoonlijkheid, enigszins geneigd tot
charitatieve en sociale bekendheid, met een voorliefde voor het openen van bazaars en het
spelen van Lady Bountiful.

Addition

Target text that is not present in the source sentence.

Wish you hadn't later."
<div>Addition</div> <div>Logical problem Coherence</div>
Ik wenste dat je het later niet had gedaan. '

Omission

Source content that cannot be found in target sentence.

"Well, I've always had a secret hankering	<div>Mistranslation Semantically Unrelated</div>	<div>Omission</div>	a detective!"
(acc)	<div>Mistranslation Semantically Unrelated</div>		
"Nou, ik heb altijd een	<div>Logical problem Coherence</div>	geheime hang naar	een detective!"

Capitalization & Punctuation

Error related to capitalization or punctuation.